Home Credit Default Risk Challenge

Por: Ing. Aron Rene Forero Africano
Para: **CNV** HUB

Problema

Muchas personas poseen problemas a la hora de pedir un préstamo en un banco, debido a su inexistente o pequeña vida crediticia.

Home Credit se encuentra en la tarea de hacer la vida de esas personas más facil, haciendo uso de datos transaccionales, información de telecomunicaciones, entre otros. Para predecir la capacidad de pago de las personas.

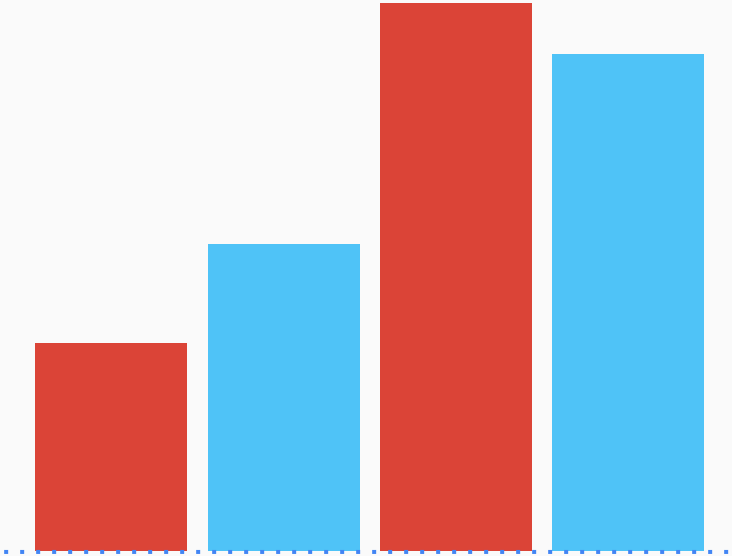

Propuesta

Análisis de Datos y Aplicación de Técnicas de Machine Learning

Proceso General

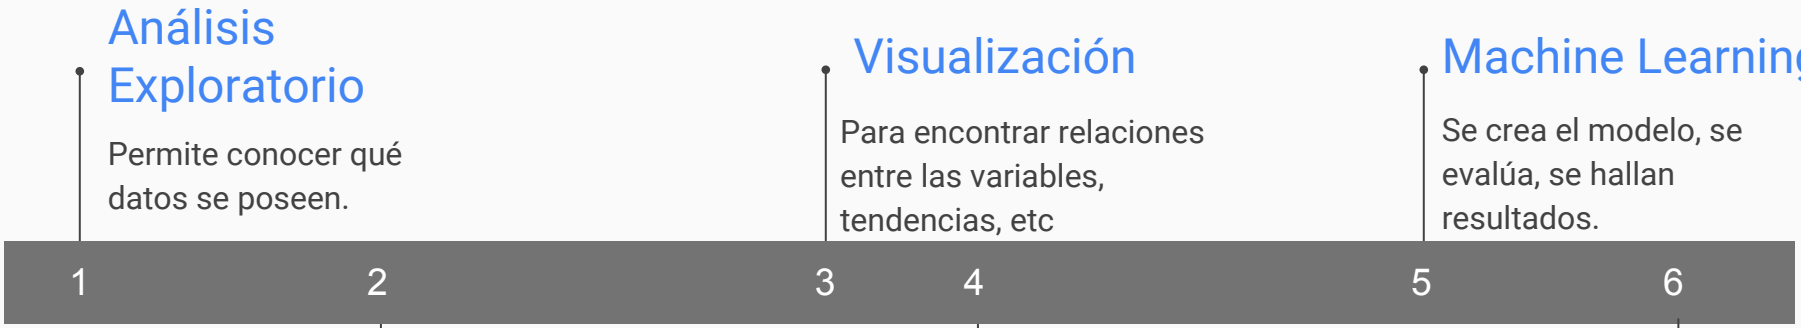

Análisis Exploratorio

Permite conocer qué datos se poseen.

Limpieza de Datos

Para obtener una base de datos plana, sin anomalías y sin vacíos

Visualización

Para encontrar relaciones entre las variables, tendencias, etc

Pre-Procesado

Preparación de los datos para ser pasados al algoritmo de predicción

Machine Learning

Se crea el modelo, se evalúa, se hallan resultados.

Conclusiones

Se concluye con la información encontrada

Exploración, Limpieza y Visualización.

Análisis Exploratorio y Limpieza de Datos

Exploración

- Se importaron los datos al notebook, y se reviso sus principales estadísticas.
- Anomalías en ciertos campos relacionados con el tiempo.
- Outliers en estos mismos campos, por ejemplo: 1000 años de trabajo en el último empleo.
- Después de arreglar el problema de los mil años, los outliers encontrados son aceptables.

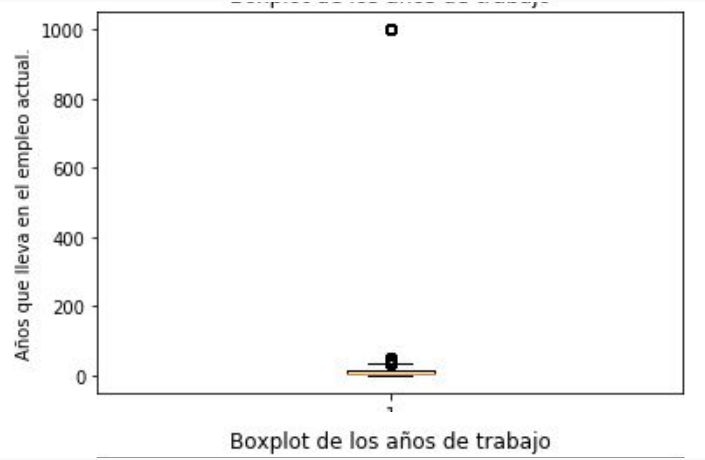

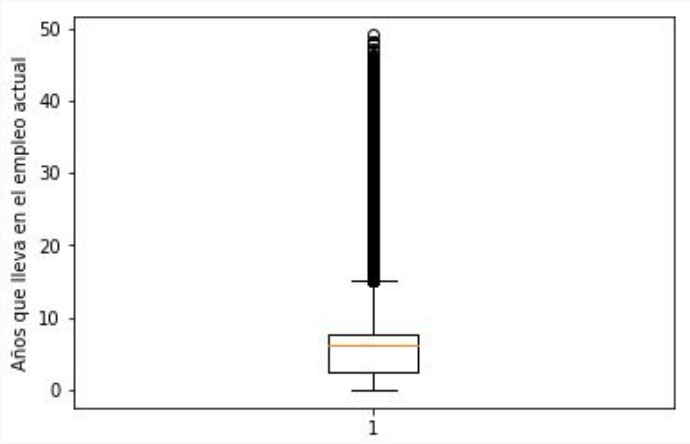

Análisis Exploratorio y Limpieza de Datos

Valores NaN

Cuando un dato no existe en la base de datos, se llena con un valor NaN. Generan problemas, y es necesario rellenarlos con datos adecuados, por medio de una estrategia de rellenado.

Algunas de las columnas se rellenaron con el valor mínimo y las demás con la media.

Análisis Exploratorio y Limpieza de Datos

TARGET desbalanceado

Algo importante es revisar nuestra variable a predecir:

- Se observó por medio de una simple gráfica de barras que, las clases estaban muy desbalanceadas.
- La clase 0 sobrepasa los 25000 registros, mientras que la clase 1 está por debajo de los 50000.

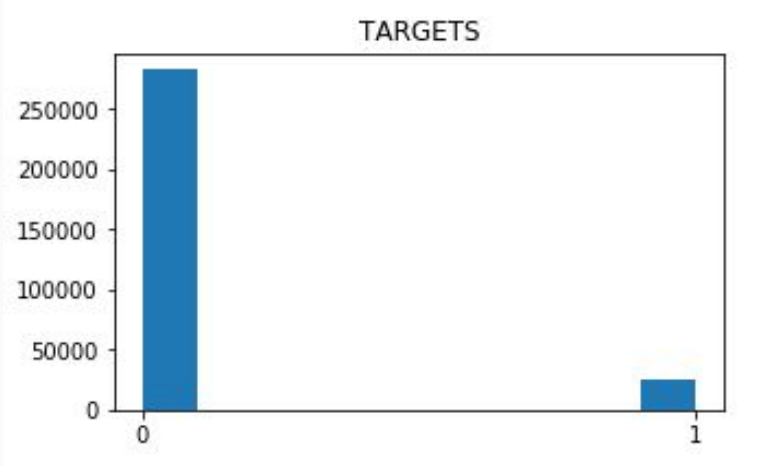

Pre-Procesado

Tratamiento de variables categóricas

Variables categóricas

- Las variables categóricas son aquellas que son de tipo string, es decir, que no son numéricas.
- Los modelos predictivos no procesan este tipo de variables así que hay que convertirlas a numéricas antes de proceder con las predicciones.

Codificación con dos estrategias

La codificación es importante antes de crear el modelo predictivo. En este caso se usaron dos tipos de codificación:

- LabelEncoder: Para las columnas con solo 2 valores únicos, así como el género que solo tiene Masculino(M) y Femenino (F).
- OneHotEncoder: Para las columnas que poseen más de dos valores únicos, así como el tipo de ocupación que puede tener muchas respuestas.

Para más Informacion sobre los codificadores:
https://medium.com/@contactsunny/label-encoder-vs-one-hot-encoder-in-machine-learning-3fc273365621

Feature Engineering

Buscando correlaciones

- Las correlaciones entre las variables y nuestro TARGET se pueden ver por medio del coeficiente de correlación de Pearson, el cual nos da un valor numérico entre -1 y 1, siendo los valores cercanos a 0 correlaciones débiles y los valores cercanos a 1 o -1 correlaciones fuertes. Por ejemplo, algunos de los más altos fueron:

EXT_SOURCE_3	-0.178919
EXT_SOURCE_2	-0.160472
EXT_SOURCE_1	-0.155317
DAYS_BIRTH	-0.078239
DAYS_EMPLOYED	-0.074958

Feature Engineering

Buscando correlaciones con un bosque aleatorio.

Se buscaron las correlaciones aplicando el algoritmo de predicción conocido como bosque aleatorio o *RandomForest* y con los resultados obtenidos se realizó una gráfica de las que más afectan al TARGET para facilitar el entendimiento.

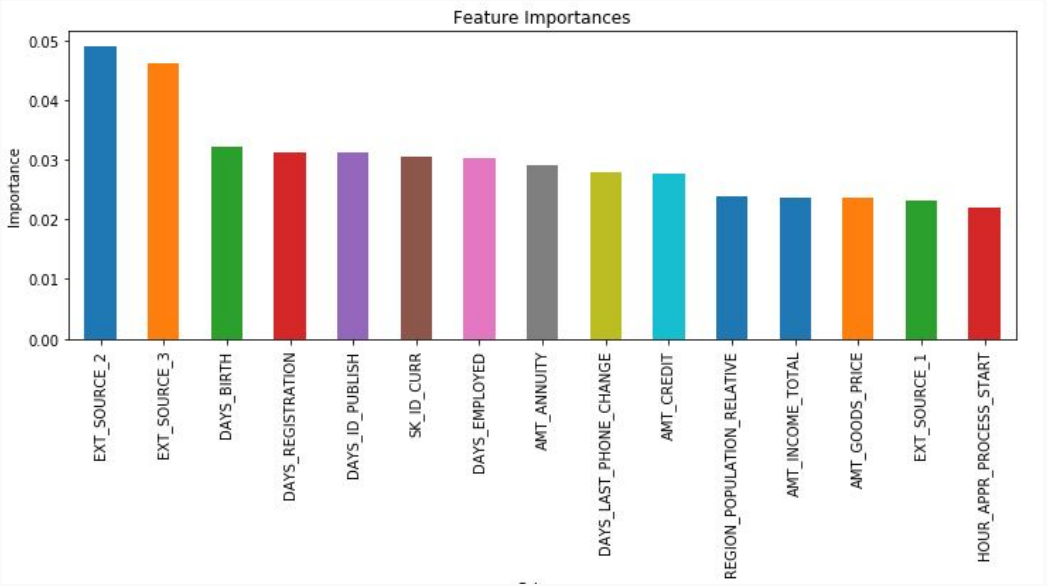

Feature Engineering

Re-Escalado de los datos

El siguiente paso que se realizó antes de los modelos de predicción fue un re-escalado, que es muy necesario porque hay variables que poseen valores entre [0 - 100], y otras variables que poseen valores entre [0 - 1], y es posible que la variable que posee valores más grandes afecte más al resultado, por sus escalado.

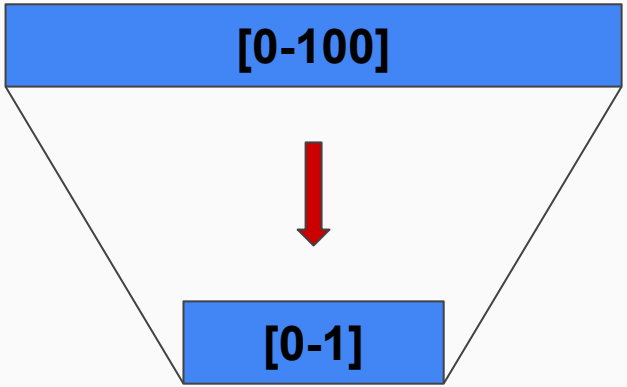

Machine Learning

Modelo Predictivos

Se usaron estos 3 algoritmos, aunque los que más se usaron fueron el de logistic regression y el gradient boosting classifier.

Como era de esperarse el Gradient Boosting fue el que nos dio un mejor rendimiento, por algo es uno de los más famosos en la actualidad.

Logistict Regression

Random Forest Classifier

Gradient Boosting Classifier

Aplicación de los Modelos Predictivos

Resultados

Se aplicaron los modelos y se obtuvieron resultados alrededor de 0.73 en una escala de [0 - 1].
Estos resultados se pueden considerar como buenos resultados.

LogisticRegression C=1(Por defecto)	LogisticRegression C=0.1	Random Forest	Gradient Boosting
0.7343	0.732	0.68	0.7344

NOTA: C es el coeficiente de regularización.

Agregación de Datos

Pre-Procesado 2

Agregación de nuevos archivos

Para mejorar el aprendizaje de nuestros modelos se agregaron los datos del archivo de **aplicaciones previas** y el archivo de **Bureau**.
Pero para agregarlos se debió realizar un preprocesado a cada archivo:

- se arreglaron las anomalías encontradas
- Se rellenaron los valores NaN
- Se codificaron las variables categóricas

Además de estos pasos se realizó una agrupación porque un cliente puede tener varios registros en las aplicaciones previas.

- Se agruparon y se realizó un promedio para cada cliente.

Luego de esto se realizó la union del archivo principal de aplicaciones con el resultante de las **aplicaciones previas** y **Bureau,** a partir de acá el último paso fue:

- Re-escalado del nuevo dataset

DataSet final

El dataset final combinación de los 3 siguientes archivos:

- Application train/test
- Previous applications
- Bureau

La combinación se realizó después del preprocesado de cada uno individualmente.

DIMENSIONES DEL NUEVO DATASET

Machine Learning Final

Aplicación de los algoritmos de predicción.

Antes de predecir...

Se realizó un llenado de los valores NaN que aparecieron a partir de la combinación de los archivos, ya que algunos clientes no tenían registros en los otros archivos.
Para rellenar estos valores NaN se usaron dos estrategias:

- llenarlos con el mínimo valor de la columna
- llenarlos con el valor promedio de la columna

	Logistic Regression	Gradient Boosting Classifier
NaN -> Mínimo	0.5725	0.7502
NaN -> Promedio	0.6055	0.7506

Hiper-parámetros fijados

Se fijó fue el coeficiente de regularización en el algoritmo de regresión logística, que se redujo para intentar obtener un mejor rendimiento.

Otro parámetro es el número de jobs a utilizar, se fijó en -1 lo que significa que se usarán todos los núcleos disponibles para realizar los entrenamientos. Esto es recomendable cuando se trabaja con archivos de gran tamaño para agilizar el proceso.

Debido al poco tiempo que poseía no fue posible aplicar un método de reducción de dimensionalidad como PCA para buscar un mejor rendimiento o por el contrario métodos como Polynomial Features para utilizar las combinaciones polinomiales de las variables.

Conclusiones

- Se observó en los últimos resultados, que se obtuvo una mejora en el rendimiento de nuestros modelos predictivos.
- Gracias a la ingeniería de características que se realizó se pudo ver que características afectan más.
- Se observó que las variables que más afectan a nuestro TARGET son las Externas, pero desafortunadamente no tenemos mucha información sobre ellas.
- Se observó que la edad de las personas afecta de manera negativa sobre nuestro TARGET, es decir entre más joven sea la persona es más posible que tenga dificultades para pagar la deuda.
- Nuestro rendimiento de 0.75 se considera bueno ya que en la competencia de Kaggle (que tuvo una duración de más o menos 3 meses), un score de 0.8 fue el ganador.

Prácticas futuras.

Como se mencionó en la sección de los hiper-parámetros, faltó tiempo para:

- Probar con otros métodos de tratamiento de datos como PCA, PolynomialFeatures
- Probar con la reducción manual de la cantidad de columnas, teniendo en cuenta las importancias de las características proporcionadas por el Random Forest
- Fusionar los otros archivos que nos brindaba la competencia.
- Probar algoritmos como Redes Neuronales.

Aunque se considera que se obtuvo un buen score, se cree que se puede mejorar más.

GRACIAS.